Detección Automática De Patologías Por Humedad En Edificaciones Mediante Yolov8 E Imágenes Adquiridas Con Dron

Mariana Sofía Meneses Díaz



31 Verano de la Investigación Científica y Tecnológica del Pacífico 2026

DELFÍN

Planteamiento del Problema

La UMSNH conserva edificios históricos y modernos cuya integridad depende de un monitoreo constante. La humedad activa y la humedad inactiva figuran entre las patologías más frecuentes: aceleran el deterioro de materiales y favorecen microorganismos y daños superficiales que comprometen la conservación de los inmuebles.

¿Por qué automatizar la detección?

La humedad activa e inactiva implican distinto grado de urgencia de intervención: diferenciarlas automáticamente permite priorizar el mantenimiento preventivo.

Subjetividad

La inspección visual tradicional depende del criterio del especialista y es difícil de estandarizar.

Tiempo y Costo

Requiere personal capacitado y, con frecuencia, equipo especial para acceder a zonas elevadas.

Acceso y Riesgo

Azoteas y fachadas de difícil acceso representan un riesgo para el personal encargado de inspeccionar.





31 Verano de la Investigación Científica y Tecnológica del Pacífico 2026

DELFÍN

OBJETIVO GENERAL

Desarrollar un sistema de detección automática, basado en visión por computadora y la arquitectura YOLOv8n, capaz de identificar y diferenciar humedad activa e inactiva en imágenes aéreas de azoteas, como apoyo al mantenimiento preventivo del patrimonio arquitectónico de la UMSNH.

OBJETIVOS ESPECÍFICOS

Construir El Dataset

Conjunto de imágenes etiquetadas en formato YOLO, con clases humedad activa y humedad inactiva, a partir de vuelos de dron sobre edificios históricos y modernos de la UMSNH.

Entrenar El Modelo

Entrenar YOLOv8n bajo distintas configuraciones de hiperparámetros, para identificar la de mejor desempeño y equilibrio entre clases.

Validar En Campo

Evaluar el modelo con videos independientes, distintos a los de entrenamiento, para medir su desempeño en condiciones reales de operación.



Metodología

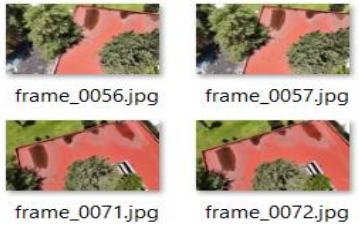
01



ADQUISICIÓN

Videos de azoteas de edificios históricos y modernos de la UMSNH, captados a 30 fps con dron de alta resolución.

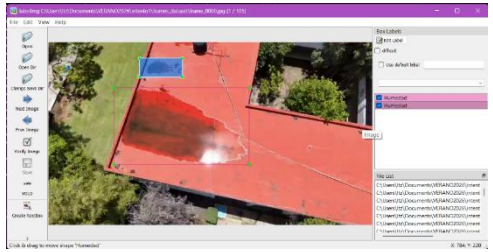
02



EXTRACCIÓN DE FOTOGRAMAS

Script en Python con OpenCV: extracción automática de imágenes a 15 fps, reduciendo redundancia.

03



ETIQUETADO

Anotación manual con LabelImg en formato YOLO, definiendo dos clases: humedad activa e inactiva.

04



ENTRENAMIENTO

YOLOv8n con Python, PyTorch y CUDA sobre GPU NVIDIA RTX 4050; dos configuraciones de hiperparámetros durante 50 épocas.



31 Verano de la Investigación Científica y Tecnológica del Pacífico 2026

Composición del Dataset

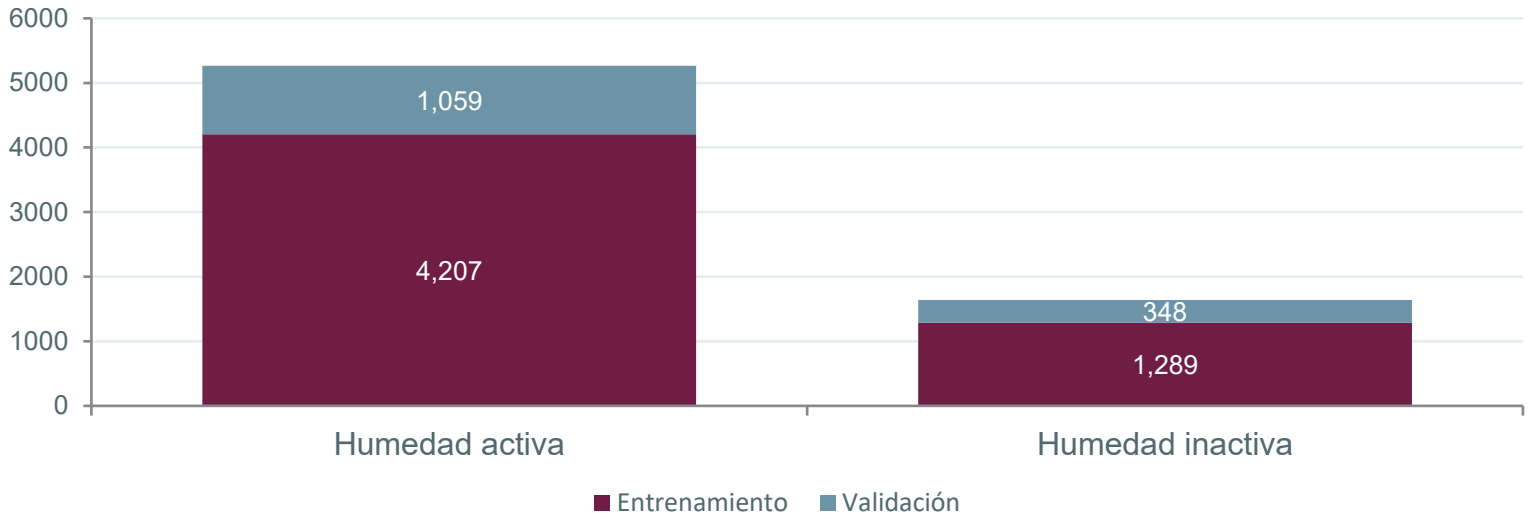
2,208 imágenes anotadas · formato YOLO · división 80/20

2,208
Imágenes anotadas
Total del dataset

1,766
Entrenamiento (train)
80% del dataset

442
Validación (val)
20% del dataset

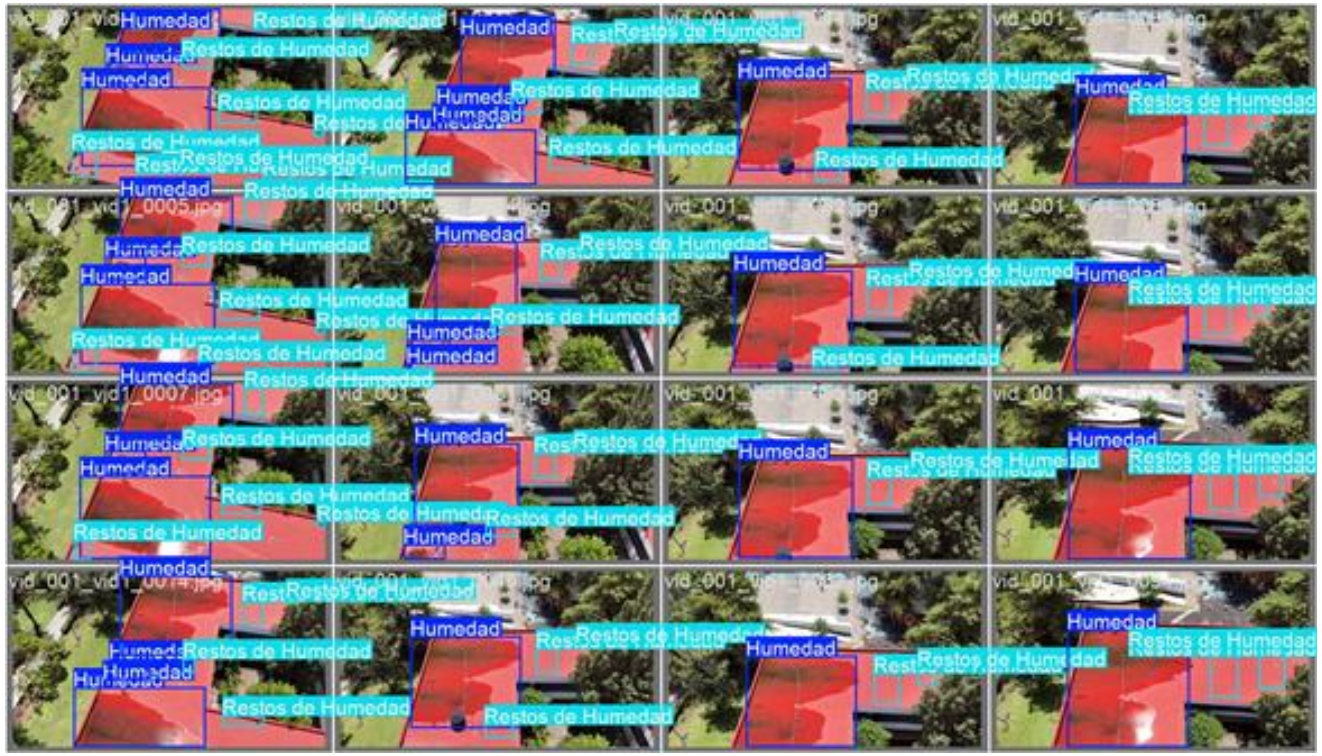
Detecciones Delimitadas Por Clase



5,266 detecciones de humedad activa · 1,637 de humedad inactiva · 6,903 en total



Anotación Manual En Formato YOLO Con Labelimg



Clases de Interés

Humedad Activa: Filtración o manchas por agua en curso.

Humedad Inactiva: Daño residual sin filtración activa.

Desempeño Por Clase

Métrica	Global	Humedad activa	Humedad inactiva
Precisión	93.4%	86.9%	82.1%
Recall (Exhaustividad)	87.9%	93.0%	91.0%
mAP50	92.6%	92.4%	92.8%
mAP50-95	64.3%	—	—

Humedad Activa

Filtración en curso: prioridad alta de intervención.

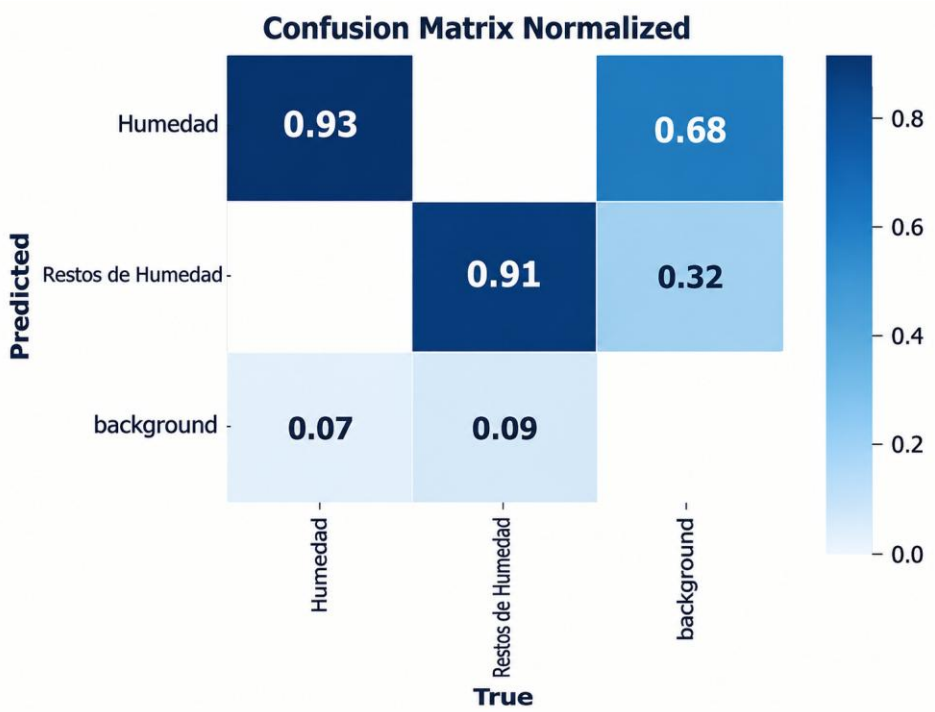
Humedad Inactiva

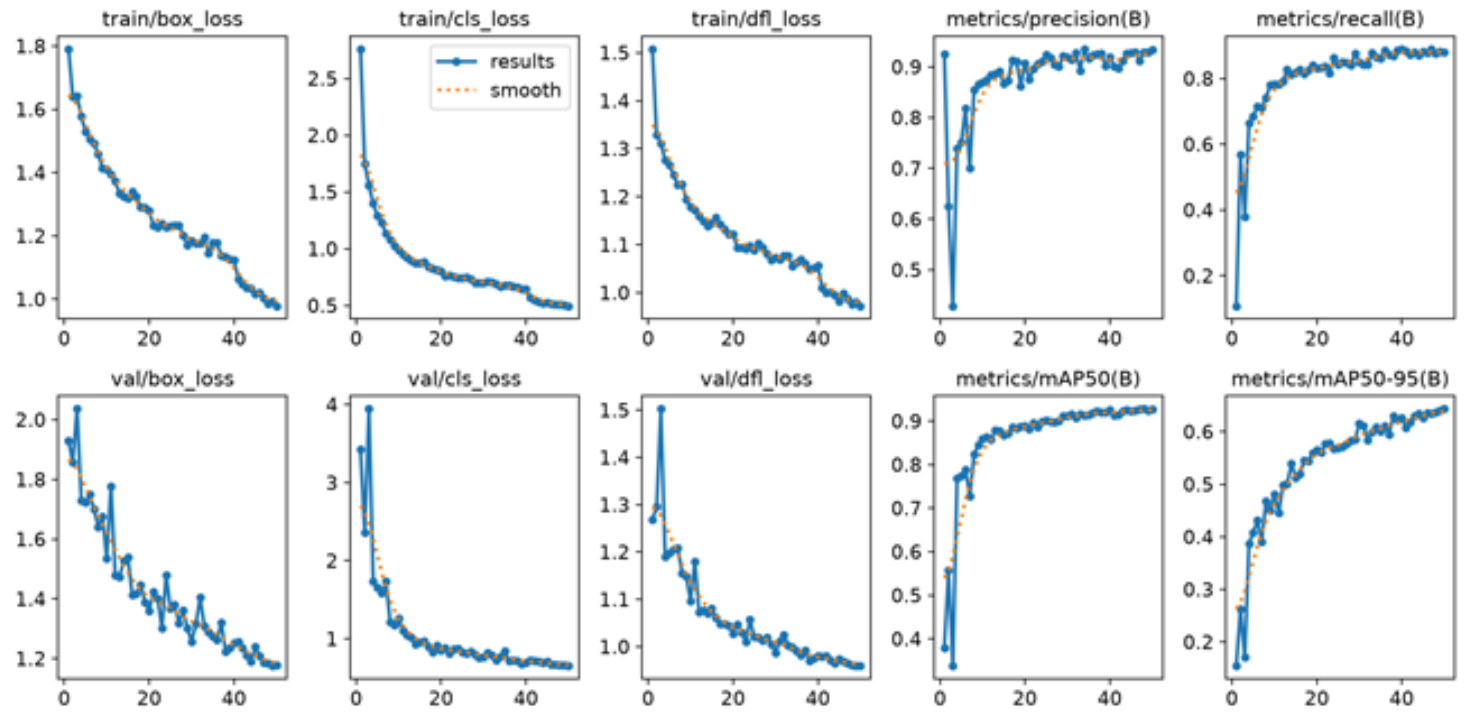
Daño residual: seguimiento preventivo.

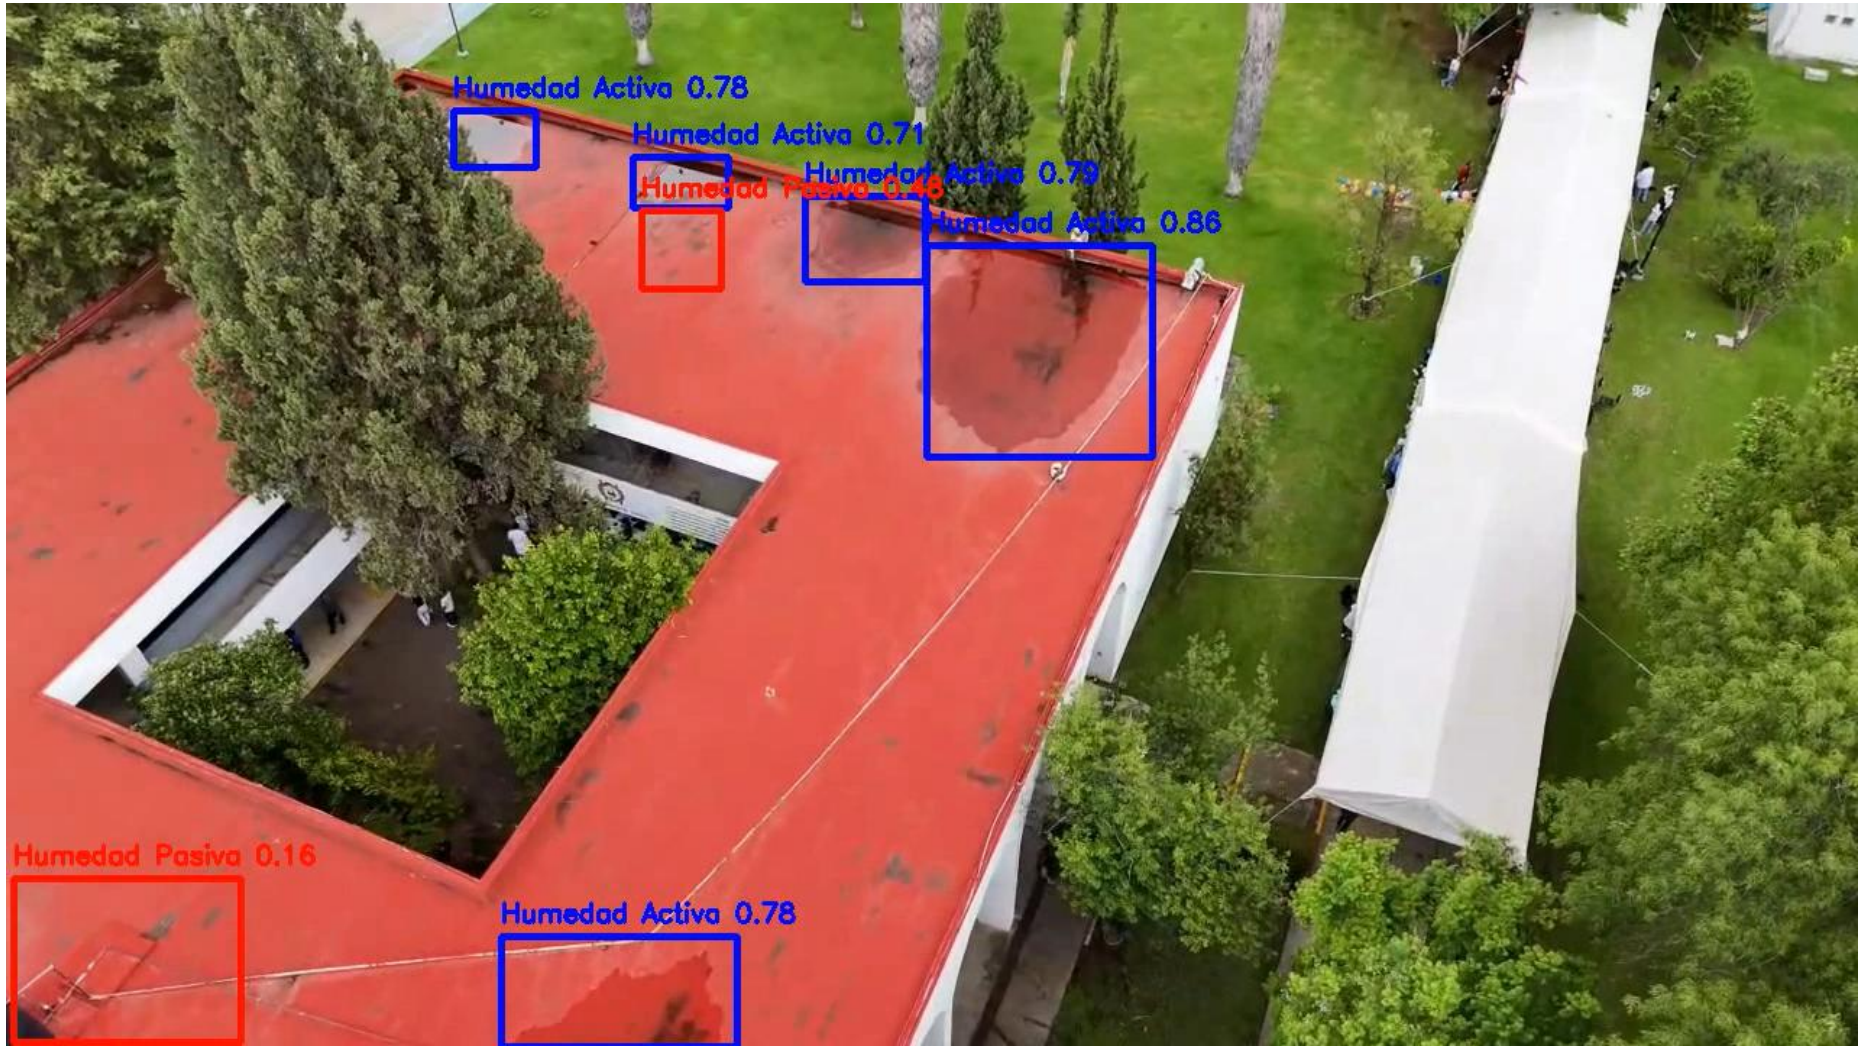
El mAP50 se mantiene equilibrado entre clases (92.4% vs. 92.8%), lo que confirma que el modelo distingue con consistencia ambas patologías, sin favorecer sistemáticamente a una sobre la otra.

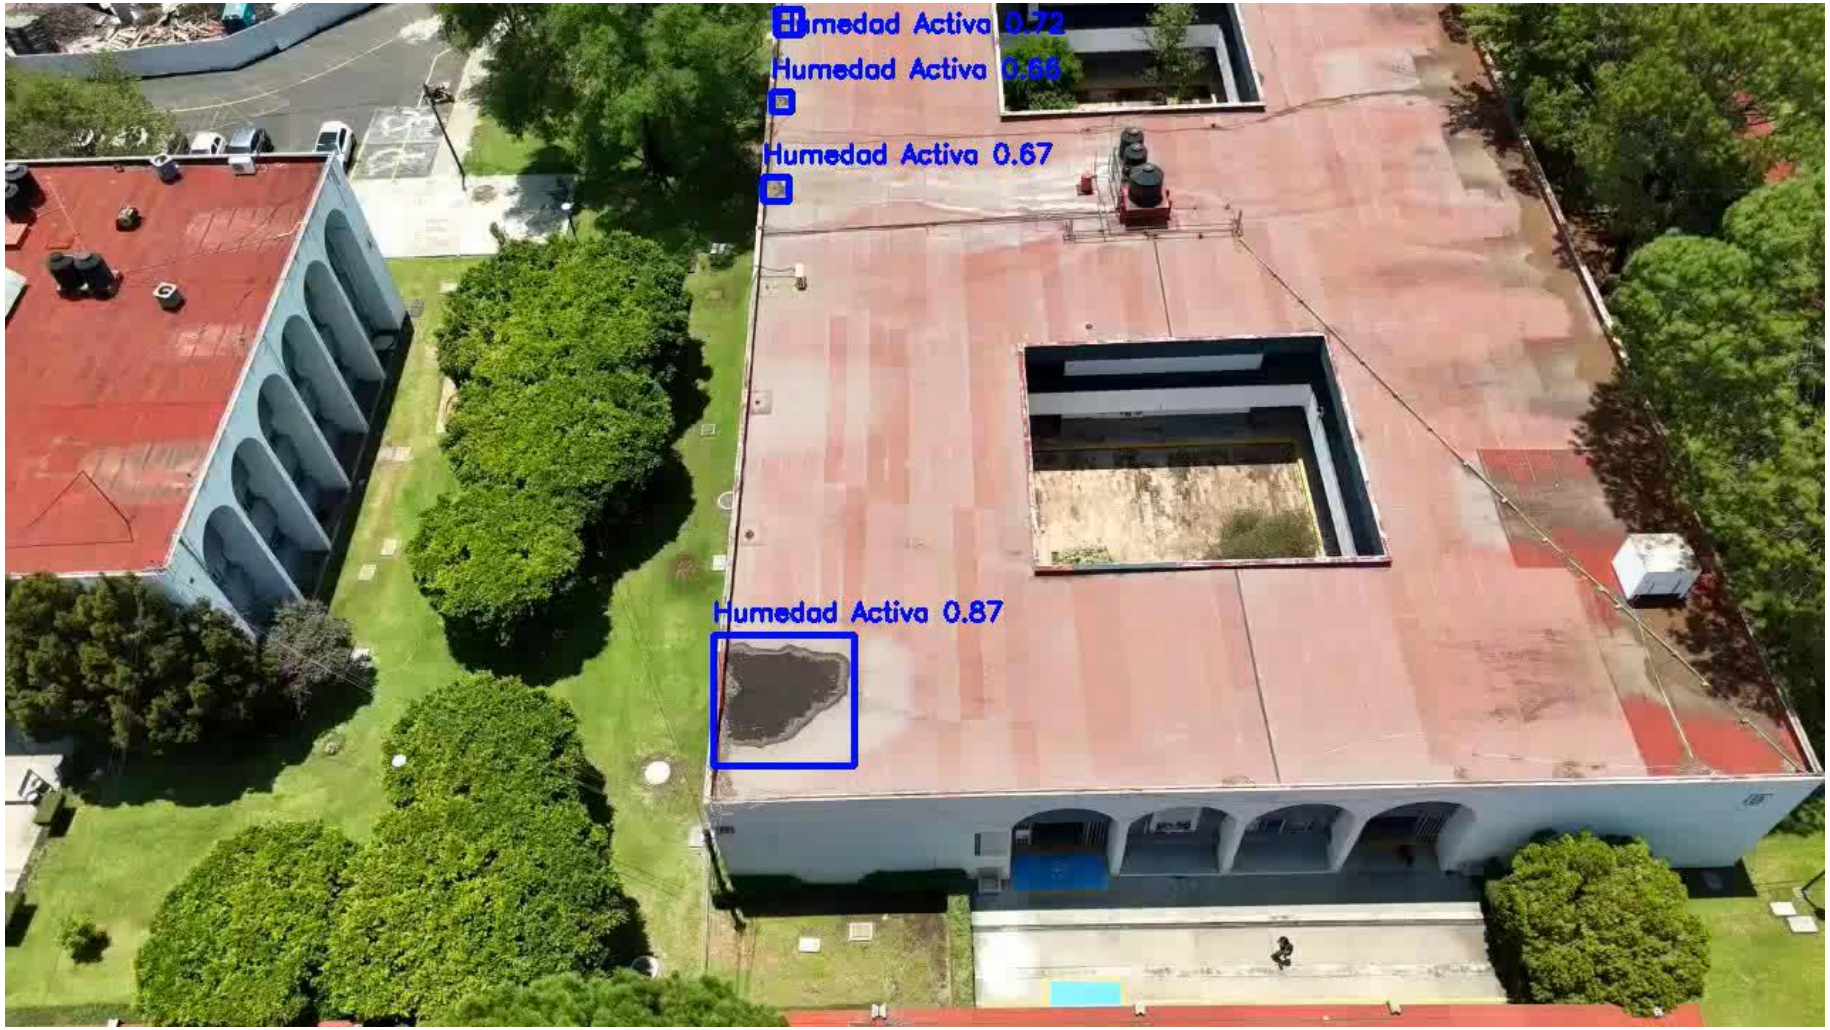
Matriz De Confusión Y Curvas De Entrenamiento

Confusión prácticamente nula entre clases; convergencia estable durante el entrenamiento






Humedad Activa 0.78
Humedad Activa 0.71
Humedad Activa 0.79
Humedad Activa 0.86
Humedad Pasiva 0.16
Humedad Activa 0.78


Humedad Activa 0.72
Humedad Activa 0.66
Humedad Activa 0.67
Humedad Activa 0.87

CONCLUSIONES

- YOLOv8n resulta viable para distinguir humedad activa e inactiva en imágenes aéreas de dron, con mAP50 superior a 92% en ambas clases.
- El balance en las funciones de pérdida durante el entrenamiento es determinante para un desempeño parejo entre clases.
- El sistema reduce la exposición del personal a inspecciones en alturas y de difícil acceso.
- La validación con videos independientes confirma un desempeño estable en condiciones reales de operación.

POSIBLES LÍNEAS FUTURAS

- Ampliar el conjunto de datos con más edificaciones y condiciones estacionales.
- Explorar la segmentación del área afectada para cuantificar la extensión del daño.
- Optimizar el modelo para inferencia en tiempo real durante el vuelo del dron.
- Extender la detección a otras patologías del patrimonio arquitectónico universitario.



31 Verano de la Investigación Científica y Tecnológica del Pacífico 2026

DELFÍN

¡Gracias por su atención!

Preguntas y comentarios

Mariana Sofía Meneses Díaz

